

# 简易解说拉格朗日对偶 (Lagrange duality) - 90Zeng - 博客园

[cnblogs.com](http://cnblogs.com) 更新2018年11月8日

## 简易解说拉格朗日对偶 (Lagrange duality)

引言：尝试用最简单易懂的描述解释清楚机器学习中会用到的拉格朗日对偶性知识，有数学专业博友，望多提意见！

### 1.原始问题

假设  $f(x), c_i(x), h_j(x)$  是定义在  $R^n$  上的连续可微函数（为什么要求连续可微呢，后面再说，这里不用多想），考虑约束最优化问题：

$$\begin{aligned} \min_{x \in R^n} & f(x) \\ \text{s.t. } & c_i(x) \leq 0, i = 1, 2, \dots, k \\ & h_j(x) = 0, j = 1, 2, \dots, l \end{aligned}$$

称为约束最优化问题的**原始问题**。

现在**如果不考虑约束条件**，原始问题就是：

$$\min_{x \in R^n} f(x)$$

因为假设其连续可微，利用高中的知识，对  $f(x)$  求导数，然后令导数为0，就可解出最优解，很easy. 那么，问题来了（呵呵。。。），偏偏有约束条件，好烦啊，要是能想办法**把约束条件去掉**就好了，bingo! 拉格朗日函数就是干这个的。

引进**广义拉格朗日函数** (generalized Lagrange function) :

$\underline{k}$

$\underline{l}$

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1} \alpha_i c_i(x) + \sum_{j=1} \beta_j h_j(x)$$

不要怕这个式子，也不要被拉格朗日这个高大上的名字给唬住了，让我们慢慢剖析！这里

$x = (x^{(1)}, x^{(2)}, \dots, x^{(n)})^T \in R^n$ ， $\alpha_i, \beta_j$  是拉格朗日乘子（名字高大上，其实就是上面函数中的参数而已），特别要求  $\alpha_i \geq 0$ 。

现在，如果把  $L(x, \alpha, \beta)$  看作是  $\alpha_i, \beta_j$  的函数，要求其最大值，即

$$\max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta)$$

再次注意  $L(x, \alpha, \beta)$  是一个关于  $\alpha_i, \beta_j$  的函数，经过我们优化（不要管什么方法），就是确定  $\alpha_i, \beta_j$  的值使得  $L(x, \alpha, \beta)$  取得最大值（此过程中把  $x$  看做常量），确定了  $\alpha_i, \beta_j$  的值，就可以得到  $L(x, \alpha, \beta)$  的最大值，因为  $\alpha_i, \beta_j$  已经确定，显然最大值

$$\max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta)$$

就是只和  $x$  有关的函数，定义这个函数为：

$$\theta_P(x) = \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta)$$

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)$$

其中

下面通过  $x$  是否满足约束条件两方面来分析这个函数：

考虑某个  $x$  违反了原始的约束，即  $c_i(x) > 0$  或者  $h_j(x) \neq 0$ ，那么：

$$\begin{aligned} \theta_P(x) = \max_{\alpha, \beta: \alpha_i \geq 0} [f(x) + \sum_{i=1}^k \alpha_i c_i(x) \\ + \sum_{j=1}^l \beta_j h_j(x)] = +\infty \end{aligned}$$

注意中间的最大化式子就是确定  $\alpha_i, \beta_j$  的之后的结果，若  $c_i(x) > 0$ ，则令  $\alpha_i \rightarrow +\infty$ ，如果  $h_j(x) \neq 0$ ，很容易取值  $\beta_j$  使得  $\beta_j h_j(x) \rightarrow +\infty$ 。

考虑  $x$  满足原始的约束，则：
$$\theta_P(x) = \max_{\alpha, \beta: \alpha_i \geq 0} [f(x)] = f(x)$$
，注意中间的最大化是确定  $\alpha_i, \beta_j$  的过程， $f(x)$  就是个常量，常量的最大值显然是本身。

通过上面两条分析可以得出：

$$\theta_P(x) = \begin{cases} f(x), & x \text{ 满足原始问题约束} \\ +\infty, & \text{其他} \end{cases}$$

那么在满足约束条件下：

$$\begin{aligned} \min_x \theta_P(x) \\ = \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta) = \min_x f(x) \end{aligned}$$

即  $\min_x \theta_P(x)$  与原始优化问题等价,所以常用  $\min_x \theta_P(x)$  代表原始问题，下标 P 表示原始问题，定义原始问题的最优值：

$$p^* = \min_x \theta_P(x)$$

原始问题讨论就到这里，做一个总结：通过拉格朗日这位大神的办法重新定义一个无约束问题（大家都喜欢无拘无束），这个无约束问题等价于原来的约束优化问题，从而将约束问题无约束化！

## 2.对偶问题

定义关于  $\alpha, \beta$  的函数：

$$\theta_D(\alpha, \beta) = \min_x L(x, \alpha, \beta)$$

注意等式右边是关于  $x$  的函数的最小化， $x$  确定以后，最小值就只与  $\alpha, \beta$  有关，所以是一个关于  $\alpha, \beta$  的函数。

考虑极大化  $\theta_D(\alpha, \beta) = \min_x L(x, \alpha, \beta)$ ，即

$$\max_{\alpha, \beta} \theta_D(\alpha, \beta) = \max_{\alpha, \beta} \min_x L(x, \alpha, \beta)$$

$$\alpha, \beta: \alpha_i \geq 0 \quad \theta_D(\alpha, \beta) = \min_x L(x, \alpha, \beta)$$

这就是原始问题的对偶问题，再把原始问题写出来：

$$\min_x \theta_P(x) = \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta)$$

形式上可以看出很对称，只不过原始问题是先固定  $L(x, \alpha, \beta)$  中的  $x$ ，优化出参数  $\alpha, \beta$ ，再优化最优  $x$ ，而对偶问题是先固定  $\alpha, \beta$ ，优化出最优  $x$ ，然后再确定参数  $\alpha, \beta$ 。

定义对偶问题的最优值：

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta)$$

### 3. 原始问题与对偶问题的关系

定理：若原始问题与对偶问题都有最优值，则

$$\begin{aligned} d^* &= \max_{\alpha, \beta: \alpha_i \geq 0} \min_x L(x, \alpha, \beta) \\ &\leq \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta) = p^* \end{aligned}$$

证明：对任意的  $\alpha, \beta$  和  $x$ ，有

$$\begin{aligned} \theta_D(\alpha, \beta) &= \min_x L(x, \alpha, \beta) \leq L(x, \alpha, \beta) \\ &\leq \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta) = \theta_P(x) \end{aligned}$$

即

$$\theta_D(\alpha, \beta) \leq \theta_P(x)$$

由于原始问题与对偶问题都有最优值，所以

$$\max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta) \leq \min_x \theta_P(x)$$

即

$$\begin{aligned} d^* &= \max_{\alpha, \beta: \alpha_i \geq 0} \min_x L(x, \alpha, \beta) \\ &\leq \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta) = p^* \end{aligned}$$

也就是说原始问题的最优值不小于对偶问题的最优值，但是我们要通过对偶问题来求解原始问题，就必须使得原始问题的最优值与对偶问题的最优值相等，于是可以得出下面的推论：

**推论：** 设  $x^*$  和  $\alpha^*, \beta^*$  分别是原始问题和对偶问题的可行解，如果  $d^* = p^*$ ，那么  $x^*$  和  $\alpha^*, \beta^*$  分别是原始问题和对偶问题的最优解。

所以，当原始问题和对偶问题的最优值相等： $d^* = p^*$  时，可以用求解对偶问题来求解原始问题（当然是对偶问题求解比直接求解原始问题简单的情况下），但是到底满足什么样的条件才能使得  $d^* = p^*$  呢，这就是下面要阐述的 **KKT 条件**

#### 4. KKT 条件

定理：对于原始问题和对偶问题，假设函数  $f(x)$  和  $c_i(x)$  是凸函数， $h_i(x)$  是仿射函数（即由一阶多项式构成的函数， $f(x)=Ax + b$ ,  $A$  是矩阵， $x$ ,  $b$  是向量）；并且假设不等式约束  $c_i(x)$  是严格可行的，即存在  $x$ ，对所有  $i$  有  $c_i(x) < 0$ ，则存在  $x^*$  和  $\alpha^*, \beta^*$ ，使得  $x^*$  是原始问题的最优解， $\alpha^*, \beta^*$  是对偶问题的最优解，并且

$$d^* = p^* = L(x^*, \alpha^*, \beta^*)$$

定理：对于原始问题和对偶问题，假设函数  $f(x)$  和  $c_i(x)$  是凸函数， $h_i(x)$  是仿射函数（即由一阶多项式构成的函数， $f(x)=Ax + b$ ,  $A$  是矩阵， $x$ ,  $b$  是向量）；并且假设不等式约束  $c_i(x)$  是严格可行的，即存在  $x$ ，对所有  $i$  有  $c_i(x) < 0$ ，则  $x^*$  和  $\alpha^*, \beta^*$  分别是原始问题和对偶问题的最优解的充分必要条件是  $x^*$  和  $\alpha^*, \beta^*$  满足下面的Karush–Kuhn–Tucker(KKT)条件：

$$\begin{aligned}\nabla_x L(x^*, \alpha^*, \beta^*) &= 0, \\ \nabla_\alpha L(x^*, \alpha^*, \beta^*) &= 0, \\ \nabla_\beta L(x^*, \alpha^*, \beta^*) &= 0, \\ \alpha_i^* c_i(x^*) &= 0, i = 1, 2, \dots, k \text{ (KKT 对偶互补条件)} \\ c_i(x^*) &\leq 0, i = 1, 2, \dots, k, \\ \alpha_i^* &\geq 0, i = 1, 2, \dots, k, \\ h_j(x^*) &= 0, j = 1, 2, \dots, l.\end{aligned}$$

关于KKT条件的理解：前面三个条件是由解析函数的知识，对于各个变量的偏导数为0（这就解释了一开始为什么假设三个函数连续可微，如果不连续可微的话，这里的偏导数存不存在就不能保证），后面四个条件就是原始问题的约束条件以及拉格朗日乘子需要满足的约束。

特别注意当  $\alpha_i^* > 0$  时，由KKT对偶互补条件可知：  $c_i(x^*) = 0$ ，这个知识点会在 SVM 的推导中用到。

## 5. 总结

一句话，某些条件下，把原始的约束问题通过拉格朗日函数转化为无约束问题，如果原始问题求解棘手，在满足KKT的条件下用求解对偶问题来代替求解原始问题，使得问题求解更加容易。

请尊重原创知识，本人非常愿意与大家分享 转载请注明出处：

<http://www.cnblogs.com/90zeng/> 作者：博客园-90Zeng

分类: [Machine learning/机器学习](#)

标签: [拉格朗日函数](#), [原始问题](#), [对偶问题](#), [KKT条件](#)

好文要顶

关注我

收藏该文



90Zeng

关注 - 11

粉丝 - 186

29

3

+加关注

« 上一篇: [机器学习中有概率论知识的小结](#)

» 下一篇: [EM算法原理详解](#)

posted @ 2014-11-09 14:14 90Zeng 阅读(41211) 评论(16) 编辑 收藏

## 评论列表

#1楼 2015-04-10 22:30 henrysky

KKT条件的第二项感觉怪怪的。这个求导了之后不是在说所有的不等式condition都等于0吗？

支持(0)反对(0)

#2楼 2016-07-19 17:36 freshing

写的不错，慢慢看

支持(0)反对(0)

#3楼 2016-07-20 11:18 freshing

.

支持(0)反对(0)

#4楼 2016-10-26 10:44 092000

“由于原始问题与对偶问题都有最优值，所以 $d^* < p^*$ ”，请问这句应该怎么理解呢

支持(0)反对(0)

#5楼 2017-03-10 09:07 明渊阁

必须是凸函数二者的最优值才相等吗？如果 $f(x)$ 是凹函数就不行吗，这个有对应的证明吗

支持(0)反对(0)

#6楼 2017-04-08 03:21 师太跟我吧

学习了，多看一遍就多一层理解

支持(0)反对(0)

#7楼 2017-05-04 01:15 郎毛毛

特别好，还没看完，明天继续看！

支持(0)反对(0)

#8楼 2017-06-06 14:48 aoguren

超赞，楼主解析问题，由浅入深，娓娓道来，值得多看几遍。

支持(0)反对(0)

#9楼 2017-12-05 11:29 寂寞的小乞丐

@ 明渊阁

凸函数和凹函数是相对应的，数学上喜欢用凸优化说明问题，当然凹优化也是可以的啊。

比如SVM

中的转化： $f(x)=1/\|W\|$ ，凸优化转化为： $f(x)=1/2*(\|W\|*\|W\|)$ ，那么凹优化就转化为

$1/(2*\|W\|*\|W\|)$ 。因为刚转到Linux下面操作，公式编辑还不熟悉，编辑的很丑。

支持(0)反对(0)

#10楼 2017-12-05 16:55 明渊阁

@ 寂寞的小乞丐

感谢博主九个月后还能回复，哈哈。当时刚接触，不太懂。

支持(0)反对(0)

#11楼 2018-01-22 10:05 \_一千零一夜

@ henrysky

我也感觉第二个写错了

支持(0)反对(0)

#12楼 2018-05-17 08:51 会长

你们高中就学导数了？后生可畏呀

支持(0)反对(0)

#13楼[楼主] 2018-06-06 17:42 90Zeng

@ 会长

要不然怎么参加高考

支持(0)反对(0)

#14楼 2018-06-06 18:09 会长

@ 90Zeng

我上高中时没有导数，有次老师算极值时用了导数，我们惊奇还有这种神奇的操作

支持(0)反对(0)

#15楼 2018-11-03 16:10 深山私塾

咋一看很乱，沉下心来看下去发现讲得很清楚，赞一个！

支持(0)反对(0)

#16楼[楼主] 2018-11-03 16:13 90Zeng

@ 深山私塾

多谢支持~ 还是上学时候写的，自己经常会忘 也会来看看复习复习

支持(0)反对(0)

[刷新评论](#)[刷新页面](#)[返回顶部](#)

注册用户登录后才能发表评论，请 [登录](#) 或 [注册](#)，[访问网站首页](#)。

#### 相关博文：

- [拉格朗日对偶性](#)
- [支持向量机SVM-番外篇-拉格朗日对偶 \(Lagrange duality\)](#)
- [拉格朗日对偶](#)
- [附录C--拉格朗日对偶性](#)
- [第七集 最优间隔分类器问题](#)

#### 最新新闻：

- [梁建章：高铁游日订单量峰值10万单 全球化带来新机遇](#)
- [AI创作了史上第一部小说，读完之后我懵了](#)
- [支付宝花呗锦鲤来了：帮你还“一整年”花呗 最高49999元](#)
- [十届双11，你的钱包如何被掏空？](#)
- [三星发布「折叠手机」后，Google第一时间提供了解决方案](#)
- [» 更多新闻...](#)



*Evernote*, 让记忆永存

[服务条款](#) | [隐私条款](#)